TRABAJO FIN DE GRADO

INGENIERÍA INFORMÁTICA

Control de navegación cazador-presa para sistemas aéreos no tripulados

Autor

Germán Rodríguez Vidal

Directores

Francisco Barranco Expósito

Álvaro Martínez Novo

Escuela Técnica Superior de Ingenierías Informática y de Telecomunicación

—

Granada, Convocatoria de Junio curso 2025/26

Control de navegación cazador-presa para sistemas aéreos no tripulados

Autor
Germán Rodríguez Vidal

Directores
Francisco Barranco Expósito
Álvaro Martínez Novo

Departamento de
INGENIERÍA DE COMPUTADORES, AUTOMÁTICA Y ROBÓTICA

Departamento de ingeniería de computadores, automática y robótica

—

Granada, Convocatoria de Junio, curso 2025/2026

Agradecimientos

Poner aquí agradecimientos.

Control de navegación cazador-presa para sistemas aéreos no tripulados

Germán Rodríguez Vidal

Palabras clave: Control de navegación, UAV, , Sistemas aéreos no tripulados, Navegación autónoma, Ardupilot, Gazebo, PID, Filtro de Kalman, Detección de Objetos

Resumen

Este Trabajo Fin de Grado propone el desarrollo de métodos de navegación autónoma para sistemas aéreos no tripulados (UAV, por sus siglas en inglés) convencionales en el caso de uso del problema cazador-presa. En concreto, se plantea una estrategia de control de navegación que permita el seguimiento a corta distancia de un UAV presa por parte de un UAV cazador, el cual debe perseguirlo en espacio abierto de forma estable y robusta. Para lograrlo, se integran métodos de control y técnicas de visión por computador que facilitan la detección, localización y seguimiento del objetivo durante la misión.

Los objetivos principales de este proyecto son, en primer lugar, validar un algoritmo de control de navegación capaz de realizar el seguimiento autónomo de un UAV presa a partir de la imagen. En segundo lugar, se persigue implementar los algoritmos desarrollados en una plataforma empotrada para su posterior validación experimental en condiciones de operación real.

Para alcanzar estos objetivos, se ha seleccionado el simulador 3D Gazebo como entorno de experimentación inicial. Esta herramienta permite evaluar los algoritmos de control en escenarios controlados, modificar variables de forma sistemática y repetir pruebas con alta precisión, lo que facilita una comparación rigurosa del rendimiento del sistema ante distintas trayectorias y condiciones dinámicas.

Una vez verificado el funcionamiento del algoritmo en simulación, mediante múltiples escenarios y perfiles de movimiento, se procederá a su validación en un campo de pruebas físico. En esta fase se analizará el comportamiento del sistema frente a situaciones reales, incluyendo perturbaciones e incertidumbres propias del entorno. El sistema se considerará satisfactorio si mantiene el seguimiento del UAV presa durante un tiempo predefinido y a una distancia fija respecto al objetivo.

Hunter-prey navigation control for unmanned aerial systems

Germán Rodríguez Vidal

Keywords: Navigation control, UAV, Unmanned aerial systems, Autonomous navigation, Ardupilot, Gazebo, PID, Kalman filter, Object detection

Abstract

This Bachelor's Thesis proposes the development of autonomous navigation methods for conventional unmanned aerial vehicles (UAVs) in the hunter-prey use case. Specifically, it presents a navigation control strategy that enables short-range tracking of a prey UAV by a hunter UAV, which must pursue it in open space in a stable and robust manner. To achieve this, control methods and computer vision techniques are integrated to facilitate target detection, localization, and tracking throughout the mission.

The main objectives of this project are, first, to validate a navigation control algorithm capable of autonomously tracking a prey UAV from image-based information and, second, to implement the developed algorithms on an embedded platform for subsequent experimental validation under real operating conditions.

To achieve these objectives, the 3D Gazebo simulator has been selected as the initial experimentation environment. This tool makes it possible to evaluate control algorithms in controlled scenarios, modify variables systematically, and repeat tests with high precision, which enables a rigorous comparison of system performance under different trajectories and dynamic conditions.

Once the algorithm has been verified in simulation through multiple scenarios and motion profiles, it will be validated in a physical test field. In this phase, the system behavior will be analyzed under real-world conditions, including disturbances and uncertainties inherent to the environment. The system will be considered satisfactory if it maintains tracking of the prey UAV for a predefined period and at a fixed distance from the target.

Yo, **Germán Rodríguez Vidal**, alumno de la titulación Ingeniería Informática de la **Escuela Técnica Superior de Ingenierías Informática y de Telecomunicación de la Universidad de Granada**, con DNI 32913011B, autorizo la ubicación de la siguiente copia de mi Trabajo Fin de Grado en la biblioteca del centro para que pueda ser consultada por las personas que lo deseen.

Fdo: Germán Rodríguez Vidal

Granada a Junio de 2026 .

D. **Francisco Barranco Expósito (tutor1)**, Profesor del Área de Arquitectura y Tecnología de Computadores del Departamento Ingeniería de Computadores, Automática y Robótica de la Universidad de Granada.

D. **Álvaro Martínez Novo (tutor2)**, Profesor del Área de XXXX del Departamento YYYY de la Universidad de Granada.

Informan:

Que el presente trabajo, titulado ***Control de navegación cazador-presa para sistemas aéreos no tripulados***, ha sido realizado bajo su supervisión por **Germán Rodríguez Vidal** , y autorizamos la defensa de dicho trabajo ante el tribunal que corresponda.

Y para que conste, expiden y firman el presente informe en Granada a Junio de mes de 2026 .

Los directores:

Francisco Barranco Expósito **Álvaro Martínez Novo**

Índice general

Índice de figuras **4**

Índice de tablas **5**

Índice de extractos de código **6**

1. Introducción **7**
1.1. Descripción del problema 7
1.2. Motivación 9
1.3. Objetivos 10
1.3.1. Objetivo General 10
1.3.2. Objetivos Específicos 10
1.4. Planificación 11
1.4.1. Detalle de las fases 11
1.4.2. Presupuesto 13

2. Estado del Arte **15**
2.1. Introducción al Estado del Arte 15
2.2. Sistemas Aéreos no Tripulados 16
2.2.1. Clasificación por configuración física 16
2.2.2. Aplicaciones actuales 18
2.3. Métodos de Control de Navegación para UAVs 21
2.3.1. Tipos de control de navegación 22
2.3.2. Conceptos de Visual Servoing (IBVS) 24
2.4. Deep Learning 25
2.4.1. Paradigmas de detección de objetos 26
2.4.2. Comparativa de modelos 27
2.4.3. YOLO 27
2.4.4. Criterios de selección de modelos 28
2.5. Metodos de Control 29
2.5.1. Controlador PID 29
2.6. Estimación de Estado y Filtrado 29
2.6.1. Filtro de Kalman 29
2.6.2. Filtro EMA 29
2.7. Geometría Proyectiva 29
2.7.1. Proyecciones de la Camara 29
2.7.2. Transformaciones de coordenadas 29
2.8. Stack de Software y Hardware 29
2.8.1. Frameworks de Comunicación Distribuida en Robótica 29
2.8.2. Computación Distribuida Seleccionada 29

2.8.3. Simulación 29
2.8.4. Simulador Seleccionado 29
2.8.5. Representación Gráfica 29

3. Metodología de Trabajo **30**
3.1. Configuración de ROS 30
3.2. Configuración y Ejecución de la Simulación en Gazebo 30
3.3. Configuración del Segundo UAV en Simulación 30
3.4. Configuración del Control Propuesto y Ejecución en Gazebo . 30

4. Implementacion **31**
4.1. Solucion Software 31
4.1.1. Preparación del Espacio de Trabajo 31
4.1.2. Solución para Simulación 31
4.1.3. Desarrollo de Scripts y Gráficas 31
4.2. Arquitectura del Sistema 31
4.3. Modulo de percepcion 31
4.4. Compensacion de Actitud y proyecccion 31
4.5. Control de Seguimiento 31
4.5.1. Control PID 31
4.5.2. Control de distancia 31
4.6. Configuración del Control Propuesto y Ejecución en Gazebo . 31

5. Pruebas y Validaciones **32**
5.1. Planificación de las Pruebas 32
5.2. Métricas de Evaluación 32
5.3. Desarrollo de los Experimentos 32
5.3.1. Segumiento del Objetivo 32
5.4. Análisis de Resultados 32
5.5. Experimentos 32

6. Conclusiones **33**
6.1. Revisión del cumplimiento de objetivos 33
6.2. Conclusiones finales 33
6.3. Futuros Trabajos 33

7. Bibliografía **34**

Índice de figuras

1.1. Logo del INTA 8
2.1. Dron de ala fija 17
2.2. Dron multirrotor 17
2.3. Dron VTOL de ala fija 18
2.4. Dron monitoreando cultivos 19
2.5. Dron utilizado en Busqueda y rescate Marítimo 19
2.6. Dron utilizado transporte de paquetes 20
2.7. Drones utilizados para operaciones militares 20
2.8. Tipos de algoritmos de visual Servoing (Elaboración propia) 22
2.9. Esquema conceptual de intercepción visual basada en visión monocular 24
2.10. Representación esquemática de una red neuronal profunda organizada en capas 26
2.11. Esquema simplificado del funcionamiento de R-CNN 27

Índice de tablas

1.1. Planificación del proyecto 11
1.2. Resumen de costes del proyecto 14

Índice de extractos de código

Introducción

1.1. Descripción del problema

El auge y la proliferación de los Vehículos Aéreos No Tripulados (UAVs), especialmente los cuadricópteros, ha transformado múltiples sectores que van desde la logística hasta la defensa, gracias a sus capacidades de despegue y aterrizaje vertical (VTOL), alta maniobrabilidad y coste relativamente bajo. Sin embargo, esta democratización tecnológica ha generado simultáneamente nuevos retos de seguridad debido a su potencial uso hostil, irrumpiendo cada vez más en espacios aéreos restringidos como aeropuertos, zonas militares e infraestructuras críticas

Las contramedidas actuales para neutralizar estas amenazas, que incluyen sistemas de interferencia electrónica y soluciones cinéticas (como láseres o torretas), presentan limitaciones significativas debido a los riesgos de daños colaterales, restricciones regulatorias y altos costes operativos. En este contexto, los cuadricópteros han surgido como una plataforma óptima para la interceptación. A diferencia de los sistemas estacionarios o de superficie, un dron interceptor opera en el mismo dominio aéreo que su objetivo, ofreciendo un mayor alcance y precisión, a la vez que minimiza las interrupciones involuntarias al tráfico aéreo legal. Además, su despliegue resulta mucho más rentable en comparación con los sistemas tradicionales de grado militar, presentándose como una solución escalable para asegurar espacios aéreos sensibles

No obstante, la eficacia de un dron cazador depende críticamente de su nivel de autonomía. El enfoque convencional de operación remota basa su éxito en la pericia del piloto humano bajo estrés y en la integridad de un enlace de radiocomunicación bidireccional en tiempo real. Esta dependencia hace que los sistemas sean detectables, limitando su escalabilidad y tiempos de respuesta. Peor aún, los vuelve extremadamente vulnerables a la latencia, a técnicas de guerra electrónica y a la inhibición de frecuencias (jamming o spoofing de GPS), amenazas predominantes que pueden dejar al cazador inoperativo en el momento crítico de la misión.

Para superar estas vulnerabilidades, este Trabajo Fin de Grado aborda el desarrollo de una solución de navegación autónoma para un escenario de interceptación cazador-presa. Se propone una estrategia de control basada en la identificación y persecución visual activa, permitiendo al UAV cazador aproximarse a su objetivo de forma precisa. Frente a la vulnerabilidad de las comunicaciones, esta solución garantiza la independencia táctica al procesar la información visual mediante algoritmos de inteligencia artificial directamente en una plataforma empotrada (on-board) en el dron. Esto permite tiempos de reacción mínimos y un seguimiento robusto que no se ve degradado por interferencias, maximizando la eficiencia de la respuesta.

A su vez, para que esta solución mantenga su viabilidad económica frente a alternativas que utilizan sensores costosos (como LiDAR o radar) que erosionan la rentabilidad de los UAVs pequeños , el sistema propuesto está diseñado para operar con un conjunto sensorial mínimo: una cámara monocular y una unidad de medida inercial (IMU).

Esta investigación se enmarca directamente en la necesidad de fortalecer la soberanía tecnológica nacional en materia de seguridad y defensa. En esta línea, el desarrollo está alineado con los intereses del **Instituto Nacional de Técnica Aeroespacial (INTA)**, con sede principal en Torrejón de Ardoz (Madrid), orientado al desarrollo de capacidades avanzadas para la detección, monitorización y neutralización de UAVs que operen de forma hostil. Uno de los objetivos de ese proyecto es precisamente el abordado en este TFG.

Figura 1.1. Logo del INTA.

Por ello, el problema específico abordado en este trabajo es demostrar que un sistema de control de navegación visual, basado en modelos de percepción profunda (Deep Learning) y algoritmos de control reactivo, permite a un UAV cazador realizar una persecución autónoma, estable y robusta en tiempo real.Los criterios principales a validar durante la investigación son:

- Mantener al UAV objetivo enfocado y centrado en el campo de visión de la cámara de forma continua, minimizando el error de seguimiento.
- Asegurar la capacidad de respuesta y maniobrabilidad del UAV cazador ante trayectorias dinámicas, aceleraciones bruscas o movimientos

imprevistos de la presa.

- Garantizar que el stack de software pueda ejecutarse manteniendo una tasa de fotogramas (FPS) óptima en hardware de recursos limitados.

Para llevar a cabo esta validación, el sistema propuesto se probará inicialmente en entornos de simulación 3D , utilizando ROS y Gazebo, integrados con ArduPilot mediante simulaciones SITL. Finalmente, tras analizar las métricas obtenidas, se preparará su despliegue en plataformas empotradas reales para su evaluación práctica.

1.2. Motivación

El uso en aumento de sistemas aéreos no tripulados en defensa con la amenaza que representan los UAVs para la seguridad nacional hace necesaria la creación de sistemas antidrón que funcionen de forma autónoma, eficaz y segura. A medida que los UAVs comerciales son más accesibles y potentes, también se incrementa el riesgo de un uso indebido: desde espiar hasta amenazar a infraestructuras críticas, áreas urbanas y eventos donde hay una gran concentración de personas. Esto ha evidenciado la apremiante necesidad de tener sistemas de neutralización reactivos y muy eficaces.

La principal motivación de este trabajo es dotar a los UAVs cazadores de la capacidad de percepción y navegación que permitan adaptarse rápidamente a maniobras evasivas o a cambios inesperados en las trayectorias de los objetivos. Se trata de ir más allá de las limitaciones de los clásicos métodos de navegación basados en control remoto o en la recepción continua de coordenadas GPS, y de ofrecer una solución basada en modelos de Deep Learning y en algoritmos de control reactivo basados en visión artificial.

Asimismo, el desafío tecnológico de combinar un sistema de detección visual con un control de navegación avanzado en un entorno de simulación, junto con su implementación en hardware real, ofrece una práctica valiosa para aplicar los conocimientos adquiridos. Esto implica integrar disciplinas como la inteligencia artificial, la teoría del control, la simulación robótica y el desarrollo de sistemas embebidos. Estas áreas son clave en la ingeniería informática y en la robótica moderna.

Este trabajo no solo busca mejorar la autonomía y precisión de seguimiento de los UAVs cazadores, sino también establecer las bases para desarrollos futuros en navegación autónoma robusta, que opere de manera independiente en el exigente campo de la seguridad y defensa.

1.3. Objetivos

1.3.1. Objetivo General

Desarrollar e implementar un sistema robusto de control de navegación autónoma para vehículos aéreos no tripulados (UAVs) capaz de realizar el seguimiento de un objetivo en tiempo real, integrando técnicas de control reactivo, algoritmos de estimación de estado y visión por computador.

1.3.2. Objetivos Específicos

Para alcanzar el objetivo general, se proponen los siguientes hitos técnicos:

- **OE1: Evaluar y optimizar modelos de percepción visual para sistemas empotrados**.Entrenar y comparar distintas arquitecturas de detección de objetos de última generación (familia YOLO) evaluando el equilibrio (trade-off) entre precisión matemática (mAP) , tiempo de inferencia y tamaño del modelo para seleccionar el modelo óptimo que garantice un seguimiento fluido en tiempo real.
- **OE2: Diseñar e implementar el lazo de control de navegación visual**.Desarrollar el algoritmo encargado de traducir las detecciones 2D de la cámara en comandos de vuelo 3D. Esto implicará el uso de transformaciones geométricas de coordenadas y la sintonización de un controlador reactivo (PID) para mantener a la presa centrada en el campo de visión.
- **OE3: Integrar la arquitectura software en un entorno de simulación de alta fidelidad**.Implementar el sistema completo utilizando ROS como middleware de comunicación, acoplando los nodos de visión y control con el simulador físico 3D Gazebo y la pila de vuelo ArduPilot mediante simulaciones SITL (Software In The Loop).
- **OE4: Validar la robustez del sistema frente a maniobras evasivas**.Diseñar y ejecutar una batería de pruebas automatizadas donde el UAV objetivo (presa) realice diferentes perfiles de vuelo dinámicos (slalom, espirales, frenadas de emergencia) para cuantificar el error de seguimiento y los tiempos de respuesta del cazador.
- **OE5: Desplegar y evaluar la viabilidad computacional en una plataforma empotrada real**. Migrar el stack de software desarrollado a un hardware de recursos limitados para verificar que el sistema es capaz de mantener la tasa de procesamiento necesaria (FPS) sin comprometer la latencia ni la seguridad del vuelo.

1.4. Planificación

La planificación del proyecto se llevó a cabo utilizando un método en cascada, siguiendo un proceso lineal donde cada etapa se basa en el éxito de la precedente. Este enfoque es el adecuado, ya que cada progreso tecnológico debe consolidar la fase anterior para reducir riesgos y fallos.

El tiempo total para la realización del proyecto se estimó en 300 horas, correspondientes a 12 créditos ECTS. Sin embargo, la asignación de este tiempo experimentó algunas alteraciones debido a la necesidad de ajustarse a otras responsabilidades personales y a los obstáculos técnicos que surgieron a lo largo del desarrollo.

En la tabla que se presenta a continuación se puede apreciar claramente la organización general del proyecto, seguida de una explicación detallada de cada etapa.

Fase	**Duración**	**Oct.**	**Nov.**	**Dic.**	**Ene.**	**Feb.**	**Mar.**	**Abr.**	**May.**
Configuración del Entorno e Integración del Controlador	1 mes	X							
Incorporación de los UAVs al Simulador	1 mes		X						
Configuración de los Controladores	2 meses			X	X				
Pruebas Simuladas y Representación Visual de los Resultados	2 meses					X	X		
Implementación del Control en UAV real	1 mes							X	
Documentación	3 semanas								X

Tabla 1.1: Planificación del proyecto.

1.4.1. Detalle de las fases

A continuación, se describe brevemente el contenido de cada una de las etapas representadas en la Tabla 1.1.

1. **Configuración del entorno e integración del controlador (octubre).** Durante esta fase se instaló y configuró el entorno de trabajo, incluyendo ROS, Gazebo, MAVROS y ArduPilot.

2. **Incorporación de los UAVs al simulador (noviembre).** Se integraron los modelos de los UAVs en Gazebo y se verificó el funcionamiento de los sensores virtuales y de los canales de comunicación. Esta etapa permitió disponer de un entorno de simulación consistente y representativo del escenario de trabajo.

3. **Configuración de los controladores (diciembre–enero).** Se desarrollaron y ajustaron los controladores necesarios para el seguimiento

visual del objetivo, así como los nodos ROS encargados de intercambiar información entre percepción, estimación y actuación. Además, se realizaron pruebas iniciales en condiciones controladas para comprobar la estabilidad del lazo de control.

4. **Pruebas simuladas y representación visual de los resultados (febrero–marzo).** Se ejecutaron vuelos de prueba en distintos escenarios simulados para evaluar métricas como el error de seguimiento, la capacidad de respuesta y la estabilidad del sistema frente a maniobras dinámicas de la presa. Los datos obtenidos se procesaron y representaron mediante gráficas que facilitaron su análisis e interpretación.

5. **Implementación del control en UAV real (abril).** El sistema desarrollado se adaptó para su despliegue en una plataforma embebida asociada al UAV real. En esta fase se realizaron ajustes de integración y las primeras verificaciones experimentales orientadas a validar el funcionamiento del sistema fuera del entorno puramente simulado.

6. **Documentación (mayo, 3 semanas).** Finalmente, se elaboró la memoria del proyecto, recopilando el desarrollo realizado, los resultados obtenidos, las conclusiones principales y las posibles líneas de mejora y trabajo futuro.

Si bien la planificación inicial resultó adecuada, durante el desarrollo del proyecto surgieron desviaciones inevitables respecto al cronograma previsto. En particular, la fase de configuración del entorno requirió más esfuerzo del estimado debido a incompatibilidades entre distintas versiones de ROS y a dificultades en la integración con MAVROS. Asimismo, la comunicación entre los UAVs presentó problemas adicionales que obligaron a realizar ajustes sucesivos en la arquitectura software y provocaron retrasos puntuales en algunas de las fases posteriores.

Las pruebas en simulación se desarrollaron de manera satisfactoria. No obstante, la incorporación de nuevas implementaciones y ajustes de diseño prolongó ligeramente esta fase, ya que durante su ejecución se detectaron pequeños errores que fue necesario corregir de forma iterativa. Aun así, el desarrollo de scripts y automatizaciones para el procesamiento y la representación de los datos contribuyó a agilizar el análisis de resultados y a hacer más eficiente el flujo de trabajo.

En conjunto, la metodología en cascada permitió mantener una estructura de trabajo clara y ordenada a lo largo del proyecto. No obstante, su carácter secuencial dificultó en determinados momentos la adaptación ágil ante incidencias imprevistas, especialmente durante las fases de integración

de módulos y depuración del entorno experimental. A pesar de estas limitaciones, el proyecto avanzó conforme a los plazos generales previstos, y los resultados obtenidos en simulación respaldan la viabilidad del enfoque de navegación autónoma propuesto como base para su posterior validación en una plataforma real.

1.4.2. Presupuesto

El desarrollo del proyecto ha implicado distintos costes asociados al uso de equipamiento informático para la ejecución de simulaciones, a la adquisición de materiales necesarios para la implementación del sistema embebido en el UAV real y al coste estimado de la dedicación personal. A continuación, se detallan los conceptos principales que conforman el presupuesto global del proyecto.

Equipo y herramientas

Durante las fases iniciales del trabajo fue necesario disponer de un equipo informático con capacidad suficiente para ejecutar simulaciones con una carga moderada tanto de procesamiento como gráfica. Para ello se utilizó un ordenador personal, cuyas prestaciones procesador de alto rendimiento, tarjeta gráfica dedicada y memoria RAM suficiente permitieron ejecutar de manera adecuada los entornos ROS, Gazebo y el resto de herramientas software empleadas en el desarrollo.

El coste estimado del equipo informático utilizado se fija, de forma aproximada, en **1.400€**.

Gastos de implementación del sistema embebido

La implementación del sistema embebido en el UAV real supuso un coste total de **2.693,10€**. Este importe incluye la adquisición de componentes estructurales, como el chasis y el tren de aterrizaje; elementos de propulsión, entre ellos motores, variadores electrónicos de velocidad (ESC) y hélices; el sistema de control y navegación, compuesto por la controladora Pixhawk Cube Orange, el módulo RTK y la estación base; los dispositivos de comunicación, como la telemetría RFD y la emisora RC; el sistema de procesamiento embebido basado en una Jetson Orin Nano; los elementos de alimentación, como baterías y convertidores DC-DC; así como cableado, conectores y diverso material auxiliar de montaje.

Horas de trabajo

La dedicación al proyecto se estima en 300 horas, correspondientes a los 12 créditos ECTS asignados. Para realizar una valoración económica orientativa del trabajo desarrollado, se considera una tarifa de 12€ por hora, representativa de un perfil junior de ingeniería [2]. Bajo esta hipótesis, el coste asociado a la dedicación personal asciende a:

$$300 \text{ horas} \times 12€ \text{ / hora} = 3.600€$$

Resumen de costes

En la Tabla 1.2 se recoge el resumen de los costes estimados del proyecto.

Concepto	**Coste (€)**
Ordenador personal para simulaciones	1.400,00
Materiales para la implementación del sistema embebido	2.693,10
Horas de trabajo	3.600,00
Total estimado del proyecto	**7693,10**

Tabla 1.2: Resumen de costes del proyecto.

Por tanto, el coste total estimado del proyecto asciende a **7693,10€**, considerando tanto los recursos materiales empleados como la valoración económica aproximada del tiempo de trabajo dedicado a su desarrollo.

Estado del Arte

2.1. Introducción al Estado del Arte

Esta sección tiene como objetivo establecer el marco teórico y tecnológico que sustenta el desarrollo de este proyecto. Dado que el control de navegación para la intercepción de vehículos aéreos no tripulados (UAV) constituye un campo multidisciplinar, resulta necesario revisar las principales tecnologías empleadas para abordar este problema [21] y fundamentar la solución propuesta.

En primer lugar, se revisan los Sistemas Aéreos no Tripulados, analizando su clasificación actual y cómo su evolución ha permitido que su utilización se extienda globalmente, pasando de aplicaciones militares a complejas tareas de investigación y servicios civiles [6, 7].

El bloque de Percepción Visual aborda el uso de Deep Learning para la detección de objetos. Aquí se analiza la arquitectura YOLO, justificando su selección por su capacidad para operar en tiempo real bajo las restricciones computacionales de un sistema embarcado [37].

El núcleo estratégico del proyecto se desarrolla en el Control de Navegación Visual. Se analizan los distintos tipos de navegación aérea, profundizando en el paradigma IBVS (Image-Based Visual Servoing) [19]. Basándose en la literatura técnica consultada, se justifica el uso de IBVS como una solución más eficiente y menos costosa en términos de procesamiento y complejidad técnica que otros enfoques [21, 23]. Asimismo, se exploran diversos métodos de control, fundamentando la elección del controlador PID como una herramienta clásica y eficaz para el seguimiento de objetivos dinámicos.

Dada la naturaleza ruidosa de las detecciones visuales, la sección de Estimación de Estado y Filtrado detalla el uso del Filtro de Kalman [39] y el filtro EMA (Exponential Moving Average). Estas herramientas son críticas para mitigar el ruido de los sensores y predecir la posición del objetivo en caso de oclusiones temporales.

Para conectar el plano de la imagen con el mundo físico, se presentan los fundamentos de la Geometría Proyectiva [42]. En este apartado se explica el funcionamiento de la proyección de la cámara y el uso de transformaciones de coordenadas, esenciales para traducir los errores en píxeles a comandos

de movimiento en el sistema de referencia del dron [40].

Finalmente, se describe el Stack de Software y Hardware, detallando los frameworks de comunicación robótica (ROS/Mavros) y las herramientas de simulación (Gazebo) que permiten la validación segura de los algoritmos desarrollados .

2.2. Sistemas Aéreos no Tripulados

Los Sistemas Aéreos no Tripulados (UAS, por sus siglas en inglés, *Unmanned Aerial Systems*) han experimentado una evolución notable en las últimas décadas. Lo que comenzó como una tecnología asociada principalmente al ámbito militar se ha transformado en una plataforma versátil con aplicaciones en ingeniería civil, agricultura de precisión, logística, inspección y vigilancia. Esta expansión ha sido posible gracias a la miniaturización de sensores y al incremento de la capacidad de cómputo embarcado, lo que ha permitido desplegar drones en escenarios complejos donde la autonomía constituye un requisito crítico .

Sin embargo, el diseño de sistemas de navegación autónoma que sean robustos, eficientes y capaces de adaptarse a entornos dinámicos y no estructurados sigue siendo uno de los principales retos actuales.

2.2.1. Clasificación por configuración física

Atendiendo a los requisitos de maniobrabilidad y a la naturaleza de la misión, los UAS pueden clasificarse principalmente según su estructura [6]:

- **Ala fija (*Fixed-wing*).** Presentan una arquitectura similar a la de la aviación convencional. Destacan por su elevada autonomía y eficiencia en vuelos de larga distancia. No obstante, su incapacidad para realizar vuelo estacionario (*hover*) los hace poco adecuados para misiones de intercepción que requieran cambios bruscos de dirección o seguimiento cercano a baja velocidad. La Figura 2.1 muestra un ejemplo representativo de esta configuración.

Figura 2.1. Dron de ala fija. Fuente: [3].

- **Multirrotores (*Multi-rotors*).** Constituyen la plataforma de referencia para este Trabajo de Fin de Grado. Su configuración, habitualmente basada en cuatro motores, permite un control directo. Su capacidad de despegue y aterrizaje vertical (VTOL), junto con su elevada agilidad, resulta esencial para mantener a un objetivo móvil dentro del campo de visión de la cámara de forma continua. La Figura 2.2 presenta un ejemplo de esta configuración.

Figura 2.2. Dron multirrotor. Fuente: [5].

- **Híbridos (VTOL *Fixed-wing*).** Tratan de combinar la autonomía del ala fija con la versatilidad del multirrotor, aunque su mayor complejidad mecánica y de control suele traducirse en un incremento del peso, el coste y la dificultad de integración. La Figura 2.3 presenta un ejemplo de plataforma VTOL de ala fija.

Figura 2.3. Dron VTOL de ala fija. Fuente: [4].

2.2.2. Aplicaciones actuales

Entre sus distintas configuraciones, el dron multirrotor se ha consolidado como la plataforma más extendida debido a su maniobrabilidad, su facilidad de despliegue y su capacidad de vuelo estacionario, cualidades especialmente valiosas en operaciones que requieren cercanía al entorno y una respuesta rápida ante cambios del escenario.

Tradicionalmente, muchas de estas operaciones han dependido de un control humano directo, en el que un operador supervisa la trayectoria, corrige desviaciones y decide cada maniobra relevante. Este enfoque puede resultar suficiente en escenarios simples o muy controlados; sin embargo, pierde eficacia cuando el entorno es dinámico, cuando aparecen obstáculos imprevistos o cuando el objetivo modifica su trayectoria de forma continua.

En este contexto, la navegación autónoma surge como una solución tecnológica necesaria no solo para mejorar el rendimiento del sistema, sino también para reducir la carga de trabajo del operador humano. En misiones prolongadas, repetitivas o de alta exigencia, la dependencia constante del pilotaje manual incrementa el riesgo de fatiga, errores de supervisión y pérdida de eficacia operativa. La incorporación de capacidades autónomas permite automatizar tareas como el seguimiento de trayectorias, la corrección del movimiento y la respuesta ante cambios del entorno, disminuyendo la intervención continua del operador. Además, este enfoque contribuye a optimizar recursos y a abaratar costes operativos, al reducir la necesidad de control manual permanente y favorecer misiones más estables, seguras y sostenibles en el tiempo.

A partir de esta idea, la navegación autónoma adquiere especial relevancia en varias situaciones de uso:

Utilización en agricultura: En el ámbito de la agricultura de precisión, la navegación autónoma permite recorrer parcelas extensas, mantener trayectorias estables y adaptar el vuelo a las características del terreno o del cultivo [11]. Esto facilita tareas como la supervisión del estado de las plantaciones, la detección de incidencias y la recopilación sistemática de información, reduciendo al mismo tiempo la intervención manual continua del operador.

Figura 2.4. Dron utilizado en agricultura. Fuente: [10].

Apoyo en emergencias y búsqueda de objetivos: En escenarios de emergencia, catástrofe o difícil acceso, la navegación autónoma permite explorar áreas amplias, evitar obstáculos y centrar la misión en la localización de objetivos de interés, como personas, embarcaciones, vehículos o puntos críticos del terreno. Esta capacidad resulta valiosa en operaciones de apoyo en emergencias, donde el sistema debe reaccionar, adaptarse a cambios del entorno y mantener una búsqueda continua [13].

Figura 2.5. Dron utilizado en busqueda y rescate Marítimo. Fuente: [12].

Transporte autónomo de mercancías: En entornos urbanos, industriales o logísticos [15], los UAV pueden convertirse en una alternativa eficiente para

el envío de pequeñas cargas, repuestos o material de primera necesidad. En este tipo de operaciones, la navegación autónoma permite reajustar la ruta ante restricciones del entorno, variaciones en el trayecto o condiciones externas no previstas, manteniendo al mismo tiempo un vuelo estable y seguro .

Figura 2.6. Dron utilizado para transporte de paquetes. Fuente: [14].

Operaciones militares y de defensa: Este es el caso de uso más próximo al enfoque de este Trabajo de Fin de Grado. En misiones de reconocimiento, vigilancia, defensa, intercepción [18, 17] y seguimiento de UAV enemigos, la capacidad de reaccionar ante amenazas dinámicas resulta fundamental. En estos escenarios, el sistema no solo debe desplazarse, sino también detectar, seguir y mantener el objetivo dentro del campo de visión, corrigiendo su trayectoria en tiempo real incluso ante maniobras evasivas.

Figura 2.7. Drones utilizados para operaciones militares. Fuente: [16].

En consecuencia, los métodos basados exclusivamente en pilotaje humano o en trayectorias rígidamente prefijadas resultan insuficientes cuando

el sistema debe desenvolverse en entornos no estructurados y frente a objetivos dinámicos. Además, este enfoque incrementa la dependencia de pilotos con un alto nivel de entrenamiento, capaces de mantener decisiones rápidas y precisas durante situaciones de elevada exigencia operativa. Por ello, este Trabajo de Fin de Grado se orienta hacia estrategias de percepción visual y control de navegación que permitan reducir esa dependencia, automatizar tareas críticas de seguimiento e intercepción y dotar al UAV cazador de una respuesta robusta, precisa y adaptable en tiempo real.

2.3. Métodos de Control de Navegación para UAVs

Para alcanzar este nivel de autonomía, el control del vehículo no puede entenderse como una acción aislada, sino como parte de un sistema integrado de Guiado, Navegación y Control, habitualmente denominado GNC (*Guidance, Navigation and Control*). Este marco organiza el comportamiento inteligente de la aeronave en tres niveles jerárquicos y complementarios: el guiado determina la estrategia de la misión y la trayectoria a seguir; la navegación estima el estado del UAV y su posición relativa respecto al entorno; y el control transforma esta información en comandos específicos de actitud y empuje. En conjunto, el sistema GNC permite cerrar el lazo entre la percepción sensorial y la respuesta dinámica del dron, un factor crítico cuando el escenario de operación cambia en tiempo real y el objetivo se mueve de forma continua .

Dentro de este esquema, el control de navegación actúa como el núcleo de decisión táctica. Su función principal es procesar la información proveniente del módulo de navegación para generar comandos de movimiento que permitan cumplir objetivos complejos, como la persecución de una presa. En este tipo de misiones, el éxito no depende únicamente de una detección correcta, sino de la capacidad del algoritmo para orquestar un movimiento fluido que mantenga al objetivo dentro del campo de visión sin comprometer la estabilidad del vuelo.

Dada la complejidad de este desafío, la literatura científica ha evolucionado hacia diversos paradigmas de control, diferenciados principalmente por la fuente de los datos y la arquitectura del procesamiento 2.8. Estos enfoques se pueden clasificar en tres grandes categorías : los métodos basados en localización global, los enfoques fundamentados en aprendizaje profundo (*Deep Learning*) y los sistemas de control basado en imagen (*Visual Servoing*). Cada una de estas metodologías presenta un compromiso distinto entre precisión, coste computacional y robustez, factores que determinan su idoneidad para operar en sistemas empotrados de recursos limitados. A continuación, se describen los fundamentos y aplicaciones de estos paradigmas

para contextualizar la solución técnica adoptada en este proyecto.

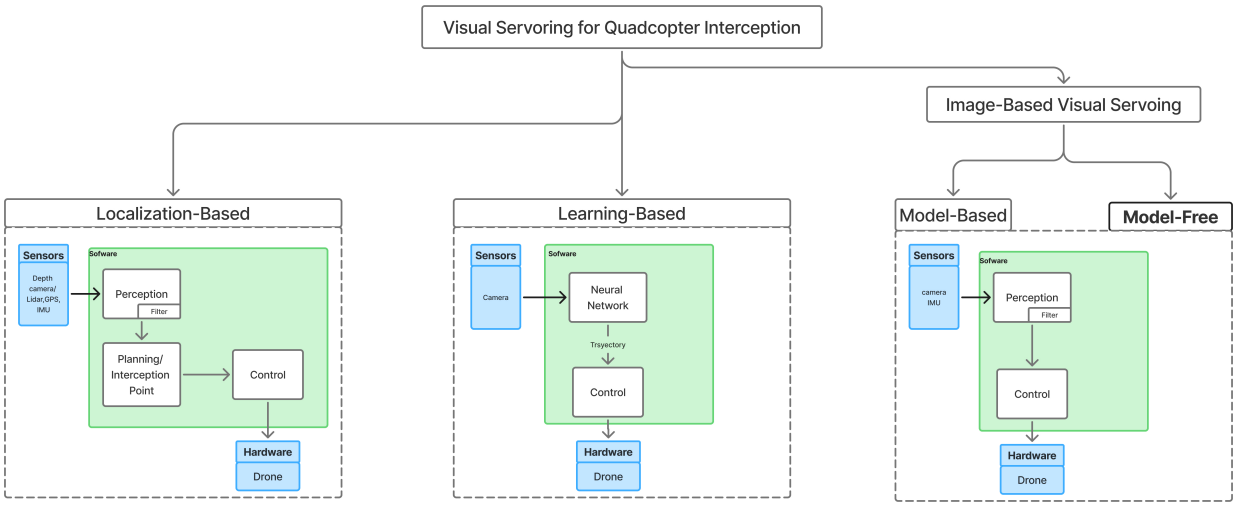

Figura 2.8. Diferencias entre los tipos de algoritmos de visual Servoing.

2.3.1. Tipos de control de navegación

Los **métodos basados en localización**, encuadrados habitualmente en el paradigma *Position-Based Visual Servoing* (PBVS), tienen como objetivo reconstruir la posición y la orientación del blanco en el espacio cartesiano a partir de la información visual [20]. Esta estimación tridimensional permite definir trayectorias de intercepción con un mayor grado de precisión, algo especialmente útil en misiones de seguimiento e intercepción con cuadricópteros. Dentro de esta familia, algunos trabajos recurren a controladores predictivos no lineales que optimizan la acción de control en un horizonte temporal, teniendo en cuenta tanto la evolución prevista del objetivo como las restricciones dinámicas del UAV. Otros enfoques emplean lazos de control sobre velocidades angulares para hacer coincidir la línea de visión con el vector de velocidad del vehículo, o modelan la trayectoria del blanco en tres dimensiones para escoger puntos de interceptación más convenientes. De igual modo, también se han propuesto arquitecturas de doble lazo PID que aprovechan los estados tridimensionales estimados del objetivo para seguir blancos terrestres o aéreos[26].

En definitiva, la principal fortaleza de PBVS radica en su capacidad para prever el movimiento del objetivo y determinar puntos de interceptación. No obstante, su rendimiento queda condicionado por una estimación fiable de la profundidad y por una calibración rigurosa de la cámara. Asimismo,

una parte importante de los trabajos revisados complementa la información visual con sensores adicionales, como radares o cámaras estéreo y de profundidad, con el fin de mejorar la reconstrucción espacial y aumentar la robustez del sistema.

Los **métodos basados en aprendizaje** delegan una parte importante del control en modelos entrenados con datos, normalmente redes neuronales capaces de inferir comandos de navegación de forma directa a partir de la información visual. Dentro de esta familia destacan enfoques de aprendizaje supervisado y, especialmente, técnicas de aprendizaje por refuerzo, que han mostrado una notable capacidad de adaptación frente al ruido sensorial y ante entornos dinámicos o poco estructurados. Esta flexibilidad resulta especialmente atractiva en tareas de intercepción, donde el dron debe reaccionar en tiempo real a cambios imprevistos de la escena o de la trayectoria del objetivo [29, 30]. No obstante, su aplicación práctica sigue presentando dificultades relevantes: requieren grandes volúmenes de datos y tiempos de entrenamiento elevados, suelen quedar condicionados por los escenarios utilizados durante el aprendizaje y continúan arrastrando problemas importantes de transferencia entre simulación y mundo real. A ello se suma la cuestión de la generalización, ya que un modelo entrenado en condiciones concretas puede perder fiabilidad cuando cambian el entorno, la dinámica del vehículo o las perturbaciones externas [31].

Por su parte, los **métodos basados en imagen**, agrupados bajo el paradigma *Image-Based Visual Servoing* (IBVS), utilizan directamente el error medido en el plano imagen para generar la acción de control. En lugar de reconstruir por completo la geometría tridimensional del objetivo, estos enfoques trabajan con características visuales como el desplazamiento del blanco respecto al centro de la imagen o la variación de su tamaño aparente. Esta decisión reduce la dependencia respecto a estimaciones geométricas completas y suele favorecer soluciones más ligeras y mejor adaptadas a plataformas embarcadas con recursos limitados [20, 21, 23].

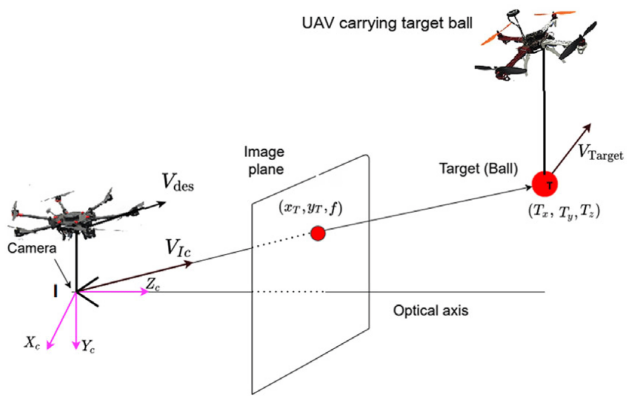

Figura 2.9. Esquema conceptual de intercepción visual basada en visión monocular. Fuente: [8].

2.3.2. Conceptos de Visual Servoing (IBVS)

Dentro de IBVS pueden distinguirse, a su vez, dos enfoques. El primero corresponde a los métodos basados en modelo, que incorporan de forma explícita la dinámica del cuadricóptero y la cinemática visual en el diseño del controlador. Estos métodos permiten respuestas más predictivas, un seguimiento más preciso y, en algunos casos, garantías formales de estabilidad, pero a cambio requieren un modelado más detallado del sistema y un mayor esfuerzo de ajuste [40, 21, 23]. El segundo enfoque es el de los métodos libres de modelo, en los que el controlador abstrae gran parte de la dinámica interna del UAV y delega la estabilización básica en el autopiloto o en los lazos de bajo nivel ya disponibles. Esta aproximación reduce la carga computacional y simplifica la integración práctica, aunque puede ofrecer una menor capacidad de respuesta ante maniobras extremadamente agresivas o escenarios muy exigentes [24, 25, 27].

Por tanto, la elección entre PBVS, enfoques basados en aprendizaje e IBVS no depende únicamente de cuál resulte más sofisticado desde un punto de vista teórico, sino de cuál se adapta mejor al contexto de aplicación. PBVS aporta una representación espacial rica, pero exige una percepción 3D precisa; los métodos basados en aprendizaje ofrecen flexibilidad, aunque todavía presentan dificultades importantes de entrenamiento y transferencia al entorno real; e IBVS proporciona una relación especialmente favorable entre simplicidad, latencia y viabilidad en tiempo real. En este Trabajo de Fin de Grado, donde la percepción visual previa ya proporciona detecciones en el plano imagen mediante Deep Learning, resulta natural cerrar el lazo de navegación aprovechando directamente esa información visual. Por ello, un enfoque IBVS libre de modelo se presenta como la opción más coherente, ya que permite conectar de forma directa la detección del objetivo con la generación de consignas de control sin introducir una complejidad geométrica o computacional excesiva. Sin embargo, para que este lazo de control sea efectivo, el sistema requiere de un "sensor virtual.^{ex}tremadamente fiable, capaz de identificar y localizar al objetivo en el plano imagen de forma ininterrumpida. Esta dependencia crítica entre la respuesta dinámica del dron y la calidad de la información visual es lo que motiva el desarrollo del módulo de percepción que se detalla a continuación.

2.4. Deep Learning

El *Deep Learning* constituye una rama del aprendizaje automático basada en redes neuronales profundas, capaces de aproximar relaciones altamente no lineales a partir de grandes volúmenes de datos. Su rasgo distintivo es el aprendizaje jerárquico de representaciones: las primeras capas capturan regularidades elementales de la señal de entrada, mientras que las capas más profundas combinan esos patrones para construir descripciones semánticas de mayor nivel.

En términos formales, una neurona artificial transforma una combinación afín de sus entradas mediante una función no lineal, de acuerdo con la expresión:

$$z = \sum_i w_i x_i + b, \quad y = \phi(z) \tag{2.1}$$

donde w_i y b representan los parámetros ajustables del modelo y $\phi(\cdot)$ introduce la no linealidad necesaria para que la red pueda representar funciones complejas. A partir de estas unidades básicas se construyen arquitecturas multicapa en las que la profundidad permite pasar de rasgos simples, como bordes o texturas, a representaciones cada vez más abstractas y útiles para tareas de alto nivel.

El entrenamiento de estas redes consiste en estimar los parámetros que minimizan una función de pérdida, es decir, una medida de la discrepancia entre la predicción del modelo y la salida deseada. Este proceso se realiza de forma iterativa mediante retropropagación, aplicando la regla de la cadena para obtener el gradiente de la pérdida respecto a cada peso:

$$\frac{\partial L}{\partial w_{ji}} = \delta_j y_i \tag{2.2}$$

A partir de este gradiente, los parámetros se actualizan mediante algoritmos de optimización basados en descenso de gradiente, por ejemplo:

$$\theta \leftarrow \theta - \alpha \nabla_\theta L(y, \hat{y}(\theta)) \tag{2.3}$$

donde α representa la tasa de aprendizaje.

Sobre esta base común se han desarrollado arquitecturas especializadas según la naturaleza de los datos, como las redes recurrentes para señales secuenciales y los *transformers* para modelar dependencias de largo alcance. Sin embargo, cuando la información de entrada es visual, las arquitecturas de mayor interés son las redes convolucionales (*Convolutional Neural Networks*, CNN), ya que explotan la estructura espacial de la imagen mediante filtros locales y compartición de pesos. Esta formulación les permite extraer de manera eficiente bordes, texturas, contornos y patrones de alto nivel,

lo que explica su papel central en tareas de clasificación, segmentación y, especialmente, detección de objetos.

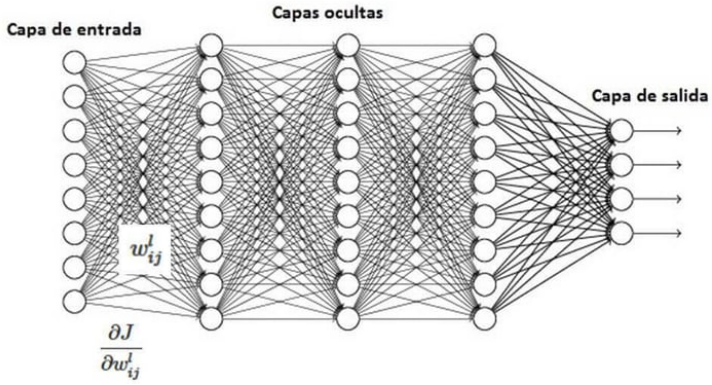

Figura 2.10. Representación esquemática de una red neuronal profunda organizada en capas. Fuente: [9].

En este Trabajo de Fin de Grado, el interés se centra en las CNN aplicadas a detección. La intercepción visual de UAV exige transformar imágenes en estimaciones fiables y frecuentes de la posición del objetivo, incluso cuando este ocupa pocos píxeles, cambia bruscamente de escala o aparece sobre fondos complejos. Por ello, la percepción visual actúa como punto de entrada del lazo de navegación y debe proporcionar una señal estable para las etapas posteriores de filtrado, estimación de estado y control. En consecuencia, el análisis se orienta a arquitecturas convolucionales de detección, cuya formulación y variantes se presentan a continuación.

2.4.1. Paradigmas de detección de objetos

La detección de objetos en Deep Learning persigue resolver simultáneamente dos tareas: determinar la clase del objeto presente en la escena y estimar su localización mediante cajas delimitadoras. Dentro de este problema, la literatura distingue principalmente entre detectores de dos etapas (*two-stage*) y detectores de una sola etapa (*one-stage*) [36, 32].

Los métodos de dos etapas separan el proceso de detección en dos fases. En una primera etapa generan regiones candidatas donde podría encontrarse el objeto y, posteriormente, clasifican y refinan cada una de esas propuestas. Este planteamiento suele ofrecer una gran capacidad de discriminación en escenas complejas, pero introduce un coste computacional más elevado y una latencia superior, lo que limita su uso cuando el sistema debe reaccionar en fracciones de segundo[33].

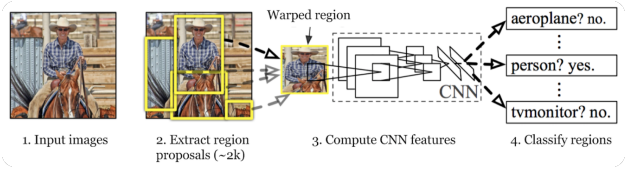

Figura 2.11. Esquema simplificado del funcionamiento de R-CNN, [33].

Por el contrario, los detectores de una sola etapa estiman directamente la clase y la localización del objeto en una única pasada de la red neuronal. Esta simplificación reduce la complejidad del pipeline y favorece tiempos de inferencia significativamente menores, una propiedad especialmente importante en plataformas embarcadas. En escenarios aire-aire, donde el objetivo puede ocupar pocos píxeles, cambiar rápidamente de escala y aparecer sobre fondos poco estructurados, la frecuencia de actualización del detector resulta tan importante como su precisión .

2.4.2. Comparativa de modelos

Desde el punto de vista de este Trabajo de Fin de Grado, la comparación entre modelos de percepción visual no debe basarse únicamente en métricas agregadas de precisión, sino en su comportamiento dentro del sistema completo. Un detector visual para intercepción de UAV debe ofrecer un equilibrio entre exactitud espacial, velocidad de inferencia y robustez frente a perturbaciones propias del vuelo, como vibraciones, desenfoque por movimiento, oclusiones parciales o cambios bruscos de perspectiva.

En la práctica, los modelos más precisos no siempre son los más adecuados si exigen recursos que exceden la capacidad de cómputo del vehículo. Del mismo modo, un detector extremadamente rápido pero inestable puede perjudicar el control si introduce falsas detecciones o desplazamientos espurios del centro de la caja delimitadora. Por tanto, la selección del modelo debe considerar simultáneamente la calidad de las detecciones y la viabilidad de su despliegue a bordo [24, 25].

En este marco, la familia YOLO destaca como una alternativa especialmente competitiva. Su popularidad no se debe únicamente a su rendimiento en bancos de prueba generales, sino también a su capacidad para adaptarse a distintas restricciones de hardware mediante variantes ligeras o más complejas, manteniendo una relación favorable entre precisión y velocidad [36].

2.4.3. YOLO

La arquitectura YOLO (*You Only Look Once*) formuló la detección de objetos como un problema unificado de regresión, en el que una sola red

neuronal predice de forma conjunta las categorías y las cajas delimitadoras presentes en la imagen [35]. Este cambio de enfoque permitió sustituir pipelines fragmentados por una inferencia más directa y eficiente, convirtiendo a YOLO en una referencia para aplicaciones de visión en tiempo real.

La evolución posterior de la familia YOLO ha introducido mejoras progresivas en el extractor de características, en la fusión multiescala y en las cabezas de predicción, lo que ha incrementado su capacidad para detectar objetos pequeños sin renunciar a una latencia reducida [36]. Esta característica es especialmente relevante en el problema abordado en este trabajo, ya que un UAV objetivo puede aparecer inicialmente como un blanco de tamaño muy reducido y aumentar su tamaño aparente conforme se acorta la distancia relativa.

Otra ventaja práctica de YOLO es que proporciona de manera directa la información necesaria para el resto del sistema: la clase detectada, la confianza asociada y las coordenadas de la caja delimitadora. A partir de estos datos es posible estimar el centro del objetivo en la imagen, calcular el error visual y alimentar las etapas posteriores de filtrado y control. Esta integración sencilla con pipelines de seguimiento e IBVS explica su presencia recurrente en trabajos de persecución, intercepción y operación autónoma de drones [24, 25, 21].

2.4.4. Criterios de selección de modelos

La elección de un modelo de percepción visual para este proyecto debe responder a criterios funcionales concretos y no únicamente a su rendimiento teórico en bases de datos genéricas. En primer lugar, el detector debe operar en tiempo real sobre hardware embarcado, de modo que su latencia sea compatible con la frecuencia del lazo de control. En segundo lugar, debe conservar un comportamiento robusto cuando el objetivo sea pequeño, esté parcialmente oculto o se desplace de forma no lineal en el campo de visión.

Asimismo, resultan determinantes el tamaño del modelo, su consumo de memoria, la facilidad de ajuste fino con un conjunto de datos específico y la estabilidad temporal de las detecciones. Este último aspecto es particularmente importante, ya que una señal visual muy ruidosa obliga a incrementar el filtrado y puede deteriorar la respuesta dinámica del sistema. En consecuencia, el modelo más adecuado no es necesariamente el de mayor precisión absoluta, sino aquel que ofrezca el mejor compromiso entre robustez, coste computacional e integración con el controlador visual [37, 36].

Bajo estos criterios, la selección de una arquitectura de la familia YOLO queda justificada como solución de percepción principal para el UAV cazador. Su equilibrio entre velocidad, precisión, flexibilidad de despliegue y

madurez tecnológica la convierte en una base sólida para extraer en tiempo real la información visual necesaria para las etapas posteriores de estimación y control.

2.5. Metodos de Control

2.5.1. Controlador PID

2.6. Estimación de Estado y Filtrado

2.6.1. Filtro de Kalman

2.6.2. Filtro EMA

2.7. Geometría Proyectiva

2.7.1. Proyecciones de la Camara

[41]

2.7.2. Transformaciones de coordenadas

2.8. Stack de Software y Hardware

2.8.1. Frameworks de Comunicación Distribuida en Robótica

2.8.2. Computación Distribuida Seleccionada

2.8.3. Simulación

2.8.4. Simulador Seleccionado

2.8.5. Representación Gráfica

Metodología de Trabajo

3.1. Configuración de ROS

3.2. Configuración y Ejecución de la Simulación en Gazebo

3.3. Configuración del Segundo UAV en Simulación

3.4. Configuración del Control Propuesto y Ejecución en Gazebo

Implementacion

4.1. Solucion Software

4.1.1. Preparación del Espacio de Trabajo

4.1.2. Solución para Simulación

4.1.3. Desarrollo de Scripts y Gráficas

4.2. Arquitectura del Sistema

4.3. Modulo de percepcion

4.4. Compensacion de Actitud y proyecccion

4.5. Control de Seguimiento

4.5.1. Control PID

4.5.2. Control de distancia

4.6. Configuración del Control Propuesto y Ejecución en Gazebo

Pruebas y Validaciones

5.1. Planificación de las Pruebas

5.2. Métricas de Evaluación

5.3. Desarrollo de los Experimentos

5.3.1. Segumiento del Objetivo

5.4. Análisis de Resultados

5.5. Experimentos

Conclusiones

6.1. Revisión del cumplimiento de objetivos

6.2. Conclusiones finales

6.3. Futuros Trabajos

Bibliografía

[1] Instituto Nacional de Técnica Aeroespacial (INTA).
Logotipo del INTA.
URL: https://www.inta.es/INTA/es/index.html.

[2] Jobted.
Salario promedio para ingeniero de software en España.
2025.
URL:
https://www.jobted.es/salario/ingeniero-software.

[3] Dron de ala fija.
Foto de dron ala fija.
URL: https://umilesgroup.com/dron-ala-fija/.

[4] Dron VTOL.
Foto de dron VTOL.
URL: https://www.foxtechuav.com/es/inspection-vtol-drone-long-endurance-2500mm-wingspan-ayk-250.html.

[5] Dron multirotores.
Foto de dron multirotores.
URL: https://www.unmannedsystemstechnology.com/es/expo/multirotor-drones/.

[6] clasificación drones 1.
clasificación drones 1.
URL: https://umilesgroup.com/tipos-de-drones/.

[7] clasificación drones 2.
clasificación drones 2.
URL: https://www.embention.com/es/noticias/tipos-de-drones-y-sus-principales-ventajas/.

[8] S. Jana, L. A. Tony, A. A. Bhise, V. VP y D. Ghose.
Interception of an aerial manoeuvring target using monocular vision.
Robotica, vol. 40, n.º 12, diciembre de 2022, pp. 4535–4554.
Publicado en línea el 03 de agosto de 2022. DOI:
https://doi.org/10.1017/S0263574722001096. URL:
https://www.cambridge.org/core/journals/robotica/article/interception-of-an-aerial-manoeuvring-target-using-monocular-vision/45EC80975FCD5727049599E55622B446.

[9] Juan Gabriel Gomila.
Problema del desvanecimiento del gradiente en IA.
Frogames Formación, 04/09/2020. URL:
https://cursos.frogamesformacion.com/pages/blog/problema-del-desvanecimiento-del-gradiente-en-ia.

[10] Imagen Dron monitoreando cultivos.
Imagen Dron monitoreando cultivos.
URL: https://uss.com.ar/corporativo/aplicaciones-de-drones-para-monitoreo-y-vigilancia-de-grandes-areas/.

[11] Web sobre Dron en la agricultura.
Web sobre Dron en la agricultura.
URL: https://www.muginuav.com/es/drones-in-agriculture-overview/.

[12] Imagen Dron Rescate Maritimo.
Imagen Dron Rescate Maritimo.
URL: https://www.drone-school.es/contratar-pilotos-y-servicios-con-drones/servicios-con-drone-para-salvamento-y-busqueda/.

[13] Web el uso del dron en emergencias y busqueda .
Web el uso del dron en emergencias y busqueda .
URL: https://aerocamaras.es/servicios-drones-profesionales/emergencias-y-rescates-con-drones/.

[14] Imagen Dron transportando paquetes.
Imagen Dron transportando paquetes.
URL: https://easy-trans.es/el-actual-uso-de-los-drones-en-el-transporte/.

[15] Web el uso del dron en logistica , trasporte.
Web el uso del dron en logistica , trasporte .
URL: https://idc.apddrones.com/transporte/uso-de-drones-en-transporte-y-logistica/.

[16] Imagen Dron uso en defensa.
Imagen Dron uso en defensa .
URL: https://geopol21.com/
como-ha-evolucionado-la-guerra-con-drones-autonomos/.

[17] Web el uso del dron en defensa.
Web el uso del dron en defensa.
URL: https://sentrycs.com/es/the-counter-drone-blog/
empowering-special-forces-with-counter-drone-solutions/.

[18] K. Chávez y O. Swed.
Emulating underdogs: Tactical drones in the Russia-Ukraine war.
2024. URL: https://www.tandfonline.com/doi/full/10.
1080/13523260.2023.2257964.

[19] Wikipedia.
Visual servoing.
URL: https://en.wikipedia.org/wiki/Visual_servoing.

[20] F. Chaumette y S. Hutchinson.
Visual servo control, part I: Basic approaches.
IEEE Robotics & Automation Magazine, vol. 13, n.º 4, 2006.
URL: https://inria.hal.science/inria-00350283.

[21] K. Yang, C. Bai, Z. She y Q. Quan.
High-speed interception multicopter control by image-based visual servoing.
IEEE Trans. Control Syst. Technol., 2024. URL:
http://arxiv.org/abs/2404.08296.

[22] K. Yang y Q. Quan.
An autonomous intercept drone system with image-based visual servoing via perspective dynamic filtering.
2020 IEEE International Conference on Robotics and Automation (ICRA), Paris, France, 2020, pp. 3944–3950. DOI:
https://doi.org/10.1109/ICRA40945.2020.9197539. URL:
https://ieeexplore.ieee.org/document/9197539.

[23] H. Yan, K. Yang, Y. Cheng, Z. Wang y D. Li.
Precise interception flight targets by image-based visual servoing of multicopter.
Sep. 2024. URL: http://arxiv.org/abs/2409.17497.

[24] P. M. Wyder et al.
Autonomous drone hunter operating by deep learning and all-onboard computations in GPS-denied environments.
PLOS ONE, vol. 14, 2019. URL: https://journals.plos.
org/plosone/article?id=10.1371/journal.pone.0225092.

[25] Z. W. Lee, W. H. Chin y H. W. Ho.
Air-to-air micro air vehicle interceptor with an embedded mechanism and deep learning.
Aerospace Science and Technology, vol. 135, 2023. URL: https://www.sciencedirect.com/science/article/pii/S1270963823000895.

[26] A. Rodriguez-Ramos, A. Alvarez-Fernandez, H. Bavle, J. Rodriguez-Vazquez, L. Lu, M. Fernandez-Cortizas, R. A. Suarez Fernandez, A. Rodelgo, C. Santos, M. Molina, L. Merino, F. Caballero y P. Campoy.
Autonomous Aerial Robot for High-Speed Search and Intercept Applications.
arXiv preprint arXiv:2112.05465, 2021. URL: https://arxiv.org/abs/2112.05465.

[27] C.A.G. van der Aa.
Design of an Image-Based Visual Servoing System for Autonomous Quadcopter Interception.
Master Thesis, Delft University of Technology, 2024. URL: https://resolver.tudelft.nl/uuid:4d8f5709-c20e-4ed2-9f62-26ce3ecde223.

[28] R. Ferede, G.C.H.E. de Croon, C. de Wagter y D. Izzo.
End-to-end neural network based optimal quadcopter control.
Robotics and Autonomous Systems, vol. 172, 2024. URL: https://resolver.tudelft.nl/uuid:16169a19-bf6b-4681-8ecc-18a9f2bd5e0f.

[29] H. Weber.
Autonomous Drone Navigation Using Reinforcement Learning Algorithms.
Scientific Journal of Artificial Intelligence and Blockchain Technologies, vol. 2, n.º 3, 2025. DOI: https://doi.org/10.63345/sjaibt.v2.i3.303. URL: https://www.researchgate.net/publication/396807493_Autonomous_Drone_Navigation_Using_Reinforcement_Learning_Algorithms.

[30] A. V. R. Katkuri, H. Madan, N. Khatri, A. S. H. Abdul-Qawy y K. S. Patnaik.
Autonomous UAV navigation using deep learning-based computer vision frameworks: A systematic literature review.
Array, vol. 23, 2024, artículo 100361. DOI: https://doi.org/10.1016/j.array.2024.100361. URL: https://www.sciencedirect.com/science/article/pii/S2590005624000274.

[31] M. Guazzaloca.
Learning-Based Control for Nano-Drones Flight: From Simulation to Reality.
Master Thesis, Alma Mater Studiorum – University of Bologna, Academic Year 2024/2025. URL: https://amslaurea.unibo.it/id/eprint/36244/1/main.pdf.

[32] SharkYun.
Computer Vision — Object Detection, One-Stage vs Two-Stage detectors.
2024. URL: https://sharkyun.medium.com/computer-vision-object-detection-one-stage-vs-two-stage-b05dbff88195.

[33] Abirami Vina.
¿Qué es R-CNN? Una descripción general rápida.
Ultralytics, 7 de junio de 2024. URL: https://www.ultralytics.com/es/blog/what-is-r-cnn-a-quick-overview.

[34] Abirami Vina.
¿Qué es R-CNN? Una descripción general rápida.
Ultralytics, 7 de junio de 2024. URL: https://www.ultralytics.com/es/blog/what-is-r-cnn-a-quick-overview.

[35] J. Redmon, S. Divvala, R. Girshick y A. Farhadi.
You only look once: Unified, real-time object detection.
CVPR, 2016. URL: http://arxiv.org/abs/1506.02640.

[36] J. Terven et al.
A comprehensive review of YOLO architectures in computer vision: From YOLOv1 to YOLOv8 and YOLO-NAS.
2023. URL: https://www.mdpi.com/2504-4990/5/4/83.

[37] Y. Zheng et al.
Air-to-air visual detection of micro-UAVs: An experimental evaluation of deep learning.
IEEE Robotics and Automation Letters, 2021. URL: https://ieeexplore.ieee.org/document/9343737.

[38] A. Lukezic et al.
Discriminative correlation filter with channel and spatial reliability.
CVPR, 2017. URL: http://ieeexplore.ieee.org/document/8099998/.

[39] R. E. Kalman.
A new approach to linear filtering and prediction problems.
1960. URL: https://asmedigitalcollection.asme.org/fluidsengineering/article/82/1/35/397706/A-New-Approach-to-Linear-Filtering-and-Prediction.

[40] H. Jabbari Asl, G. Oriolo y H. Bolandi.
An adaptive scheme for image-based visual servoing of an underactuated UAV.
Int. Journal of Robotics and Automation, vol. 29, 2014. DOI: https://www.google.com/url?sa=t&source=web&rct=j&opi=89978449&url=https://www.researchgate.net/publication/260173544_An_adaptive_scheme_for_image-based_visual_servoing_of_an_underactuated_uav&ved=2ahUKEwiCisPGve2TAxVnxgIHHTv8DRkQFnoECBkQAQ&usg=AOvVaw23lbIYBAzu8TNIdwwOtQ4n.

[41] OpenCV.
Camera Calibration and 3D Reconstruction.
URL: https://docs.opencv.org/4.x/d9/d0c/group__calib3d.html.

[42] CameraModels.
Camera Models.
URL: https://web.stanford.edu/class/cs231a/course_notes/01-camera-models.pdf.